



SAPIENZA  
UNIVERSITÀ DI ROMA

## Student face detection, flow prediction and class-room optimal allocation

Facoltà di Ingegneria dell'Informazione, Informatica e Statistica  
Corso di Laurea in Ingegneria Informatica

Candidato

Francesco Zappia

Matricola 1757366

Relatore

Roberto Capobianco

Correlatore

Lavinia Amorosi

Anno Accademico 2019

---

**Student face detection, flow prediction and classroom optimal allocation**

Tesi di Laurea. Sapienza – Università di Roma

© 2019 Francesco Zappia. Tutti i diritti riservati

Questa tesi è stata composta con L<sup>A</sup>T<sub>E</sub>X e la classe Sapthesis.

Email dell'autore: [zffromGerace@gmail.com](mailto:zffromGerace@gmail.com)

## Sommario

Questa tesi è incentrata sullo sviluppo di un'applicazione da utilizzare in ambito universitario atta ad automatizzare il processo di raccolta dati riguardanti il flusso di studenti in particolari circostanze (temporali ed accademiche) utilizzati a loro volta per stimare il numero di allievi presenti in nuove contesti; i risultati vengono in seguito impiegati per assegnare le diverse classi a set di aule rispettivamente con capienze adatte a soddisfare la loro richiesta ottimizzando la loro allocazione in base a specifiche ed ulteriori richieste.



# Contents

<b>1</b>	<b>Introduzione</b>	<b>1</b>
1.1	Il problema . . . . .	1
1.2	Struttura del documento . . . . .	1
1.3	Codice sorgente . . . . .	3
<b>2</b>	<b>State of the art</b>	<b>5</b>
2.1	Face Detection . . . . .	5
2.1.1	Problematiche comuni . . . . .	5
2.1.2	Approcci feature-based . . . . .	5
2.1.3	Algoritmo Viola-Jones per la Face Detection . . . . .	7
2.2	Regressioni e Machine Learning . . . . .	9
2.2.1	Reti neurali . . . . .	9



# Chapter 1

## Introduzione

### 1.1 Il problema

In ambito universitario è problematica molto comune quella di cercare di assegnare aule a gruppi di studenti in modo tale da rispettare le richieste in numero di posti di ciascuno di essi senza nemmeno concretamente conoscere il numero di allievi che frequenteranno realmente il corso in questione, dovendo l'istituto assegnarle in anticipo rispetto all'inizio delle lezioni.

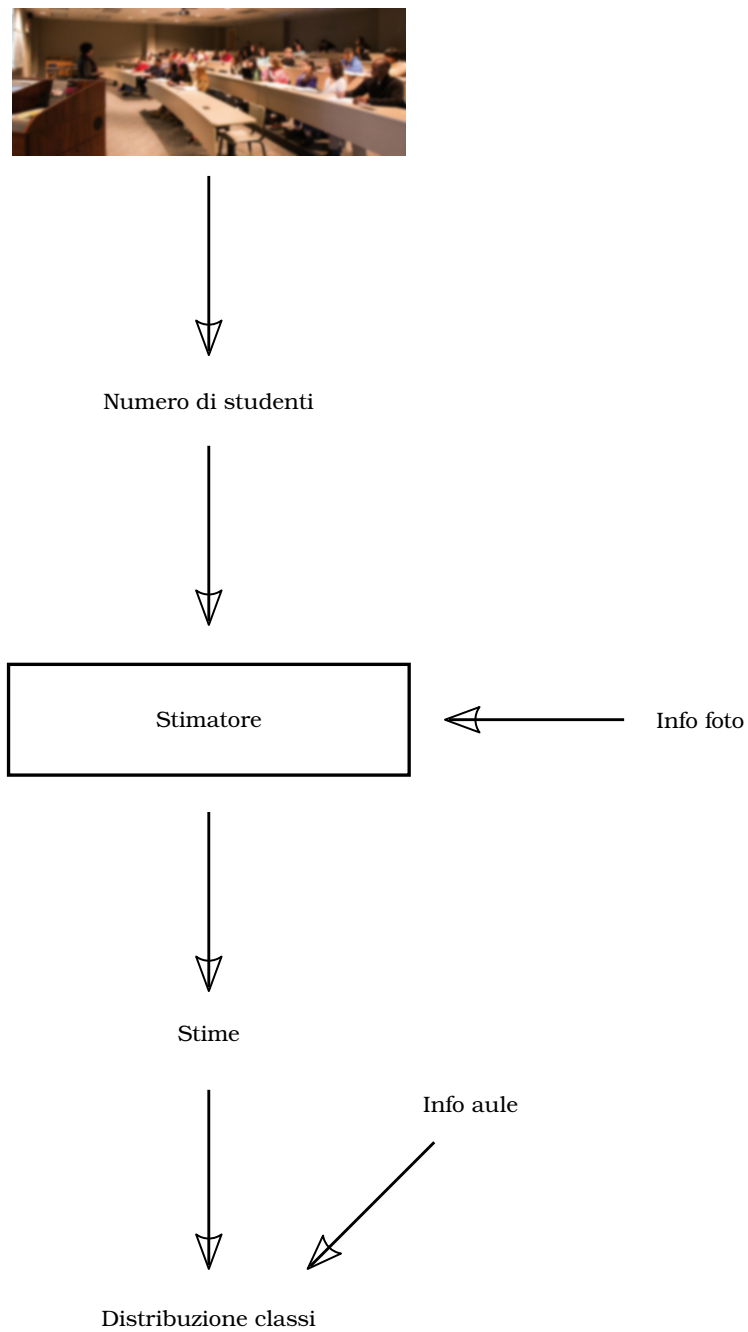
Si pone quindi l'ulteriore problema di facilitare la raccolta di dati che permetta di effettuare delle stime più accurate, quindi di registrare in modo automatico la partecipazione degli universitari a ciascuna lezione e quindi inferire attraverso di essi queste stime.

Quest'applicazione si pone l'obiettivo di risolvere esattamente questa problematica (il funzionamento è illustrato in 1.1): a partire da foto (che si intende essere di aule) riconosce il numero di volti e quindi di studenti in essa presenti. Questa informazione, associata ad informazioni riguardanti la lezione in questione, viene fornita insieme a quest'ultime ad uno stimatore che, in base ai dati ricevuti cerca di costruire un modello matematico capace di stimare il flusso di allievi in nuove e richieste situazioni: delle stime che verranno impiegate per distribuire ciascun gruppo nelle diverse aule con data capacità in modo ottimale, cercando cioè di massimizzare il valore di una certa funzione matematica che rappresenta il problema di allocazione.

### 1.2 Struttura del documento

Il documento è strutturato in

- **State of the Art**, in cui vengono accennati i concetti teorici utilizzati per la risoluzione del problema; vengono analizzati articoli e fonti che hanno affrontato le stesse problematiche.
- **Metodo**, nel quale sono approfondite le metodologie usate per la realizzazione dell'applicazione e vengono trattate ulteriori questioni sorte nell'implementazione.
- **Risultati**, che illustra gli esiti e l'efficienza della realizzazione scelta.



**Figure 1.1.** Il flusso di funzionamento dell'applicazione



- **Conclusioni**, contenente le osservazioni finali dedotte dai risultati ottenuti.

## 1.3 Codice sorgente

Il codice completo di questa applicazione è accessibile su GitHub al seguente indirizzo

`https://github.com/morpheusthewhite/celephais/`;

analogamente è stato pubblicato il codice  $\text{L}^{\text{A}}\text{T}_{\text{E}}\text{X}$  di questa tesi al link

`https://github.com/morpheusthewhite/bachelor-thesis`.



## Chapter 2

# State of the art

In questo capitolo saranno inizialmente esposti i concetti teorici alla base dell'applicazione sviluppata: dagli algoritmi più comuni per la **Face Detection** ad un'introduzione al **Machine Learning** per finire poi con elementi di **Programmazione Lineare Multiobiettivo**.

Verranno quindi analizzati precedenti progetti che hanno affrontato le stesse problematiche.

### 2.1 Face Detection

La Face Detection è una tecnologia che permette di localizzare ed estrarre da un'immagine la regione contenente un volto [DDB15]; ha oggi diverse applicazioni ed utilizzi, dal video coding al content-based image retrieval.

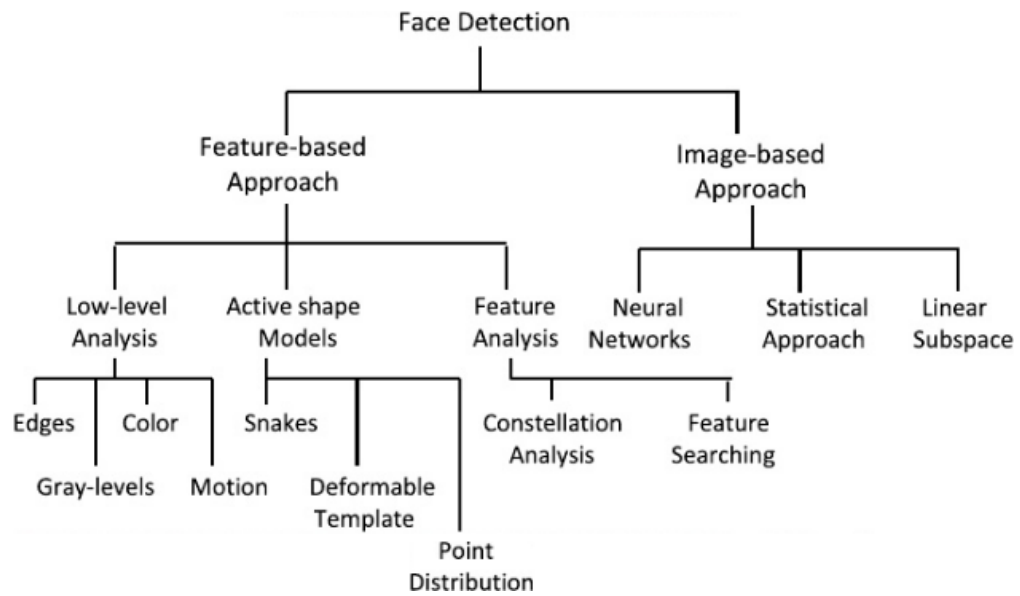
#### 2.1.1 Problematiche comuni

Le sfide che una tecnica di face detection si trova ad affrontare sono solitamente ([DDB15]):

- **Occlusione.** Spesso parte dei volti sono nascosti da oggetti e/o altri volti
- **Espressioni.** L'aspetto dei volti è fortemente influenzato dall'espressione della persona.
- **Posa.** La posizione da cui è scattata l'immagine influenza la prospettiva del volto (2.2).
- **Luminosità.** Livelli di luminosità eccessivi o troppo bassi impediscono di riconoscere contorni e linee del viso.

#### 2.1.2 Approcci feature-based


In un periodo di ricerca che coinvolge circa gli ultimi trenta anni sono state usati diversi approcci che permettessero di sviluppare tecniche di face detection (2.1), dividendosi principalmente in due categorie: **Feature-based** e **Image-based**.



**Figure 2.1.** Diversi approcci alla face detection



**Figure 2.2.** Un classico esempio di problema di face detection



**Figure 2.3.** Al valore dei pixel nella regione bianca viene sottratto il valore nella regione scura

Nei primi vengono solitamente estratte le feature di un volto da un'immagine (come ad esempio occhi, labbra, sopracciglia) per poi verificare, attraverso la relazione che persiste tra di loro, la presenza di un volto.

All'interno di questa categoria possono essere individuate ulteriori distinzioni ([DDB15], 2.2):

- **Low Level Analysis.** Feature vengono estratte basandosi sulle proprietà dei pixel come ad esempio colore o valore nella scala di grigi.
- **Feature Analysis.** Vengono sfruttate le proprietà geometriche del volto per cercare di localizzare ed individuare le diverse parti del viso.
- **Active shape models.** Questi modelli, che vanno da *snakes* ai PDM (point-distributed models) sono usati per l'estrazione di feature complesse e per tracciare le iridi degli occhi e le labbra.

### 2.1.3 Algoritmo Viola-Jones per la Face Detection

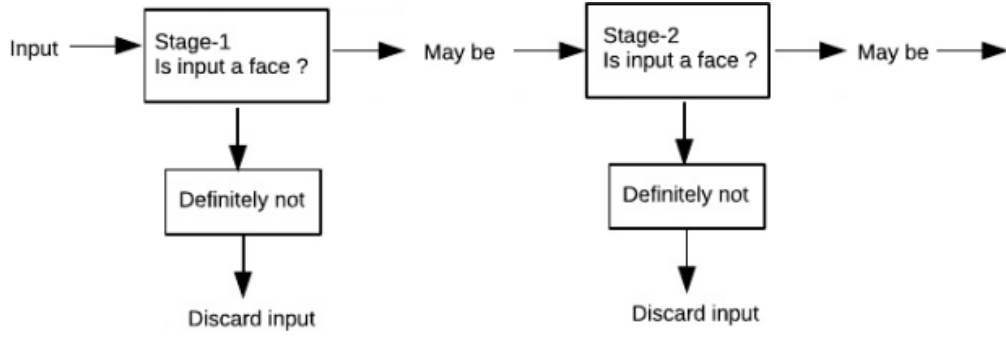
Invece tra gli svariati approcci **Image-based** uno che ha avuto particolare successo, soprattutto per la velocità di calcolo che permette il suo utilizzo in applicazioni che utilizzano grandi moli e flussi di immagini, è l'algoritmo Viola-Jones.

Esso fa uso di Haar functions per il l'individuazione delle features, i.e. si basa sul calcolo della somma e differenza di pixel in particolari rettangoli [VJ04], come mostrato in 2.3.

Il calcolo viene enormemente velocizzato attraverso le *integral images*, immagini in cui il valore dei pixel è pari alla somma dei pixel in alto a sinistra, i.e.

$$ii(x, y) = \sum_{x' \leq x, y' \leq y} i(x', y') \quad (2.1)$$

con  $ii(x, y)$  il valore del pixel nella *integral image* e  $i(x', y')$  il valore nell'immagine originale.



**Figure 2.4.** Struttura dei classificatori a cascata

Tali *Haar functions* vengono usate quindi da **classificatori**, delle funzioni che mappano un'osservazione (in questo caso un insieme di pixel) su un set finito di valori, in questo caso [Wan14]  $f : \mathbb{R}^d \rightarrow \{-1, 1\}$ .

Attraverso un Ada Boosting questi singoli ed imprecisi classificatori vengono combinati tra di loro per ottenere un classificatore "forte" che risulta essere molto più accurato [Sch13] dei singoli.

Dato un esempio da classificare  $x$ , l'esito della classificazione "forte" è pari a

$$F(x) = \sum_{t=1}^T \alpha_t h_t(x) \quad (2.2)$$

con  $h_t(x)$  classificatore "debole" a cui corrisponde un peso "di voto" pari a  $\alpha_t$ : il risultato è quindi ottenuto come la maggioranza pesata delle classificazioni deboli.

Il rendimento può essere ulteriormente migliorato con l'utilizzo di classificatori a cascata (2.4). Un classificatore a cascata è costituito da diversi *stages*, ognuno contenente uno classificatore "forte", ciascuno dei quali determina se la finestra in input non contiene sicuramente un volto oppure potrebbe. Quando viene predetta l'assenza certa di un viso l'immagine viene scartata, altrimenti è passata allo *stage* successivo [DDB15].


## 2.2 Regressioni e Machine Learning

La regressione è una tecnica statistica utilizzata per determinare la relazione che persiste tra due o più variabili: essa è principalmente adoperata per predizioni e inferenze.

Nella sua forma più semplice (bivariata) la regressione mostra la relazione tra una variabile indipendente  $X$  ed una variabile dipendente,  $Y$ , attraverso un'equazione del tipo

$$Y = \beta_0 + \beta_1 X + u \quad (2.3)$$

La regressione riesce quindi a quantificare quanto la variazione di una variabile è dipendente dalla variazione di un'altra; quello che invece la non è capace di dimostrare è la casualità, la quale è dimostrata solo analiticamente [CC08].



**Figure 2.5.** Un esempio di utilizzo di regressione lineare: la retta cerca di stimare la relazione tra le due grandezze raffigurate


### 2.2.1 Reti neurali

Negli ultimi decenni il Machine Learning è diventato uno dei principali strumenti utilizzati in ambito informatico grazie alla grande mole di dati che è possibile ormai raccogliere e si può addirittura pensare che il suo influsso negli prossimi anni si accrescerà ulteriormente [SV08].

In questo ambito ricoprono grande importanza le reti neurali, un tecnologia che si è rivelata molto adatta all'individuazione ed al riconoscimento di pattern statistici [Bis06], in particolare i *multilayer perceptron*, i quali si basano sulla combinazione di una serie di funzioni con pesi variabili.

In ciascuno dei nodi del primo livello ad esempio (come mostrato in 2.6) viene calcolato un certo valore di attivazione pari a

$$a_j = \sum_{i=1}^D w_{ij}^{(1)} x_i + w_{j0}^{(1)} \quad (2.4)$$



**Figure 2.6.** Un esempio di rete neurale *multilayer perceptron* in cui è possibile distinguere diversi livelli di nodi: un livello di input, due layer nascosti ed uno di output

con  $D$  numero di ingressi della rete,  $x_i$  valore dell'input  $i$ -esimo; i  $w_{j0}^{(1)}$ , chiamati *bias*, sono coefficienti fissati del primo layer e  $w_{ij}^{(1)}$ , chiamati *weights*, coefficienti che verranno modificati per adattarsi al modello che dovranno stimare.

L'output del nodo  $j$ -esimo (che verrà in seguito utilizzato come precedentemente era stato fatto con gli input) sarà quindi [Bis06]

$$z_j = h(a_j) \quad (2.5)$$

con  $h()$  funzione non lineare definita *activation function*, che solitamente corrisponde ad una *tanh*, ad una ReLU, definita come [Nwa+18]

$$ReLU(x) = \max(x, 0) \quad (2.6)$$

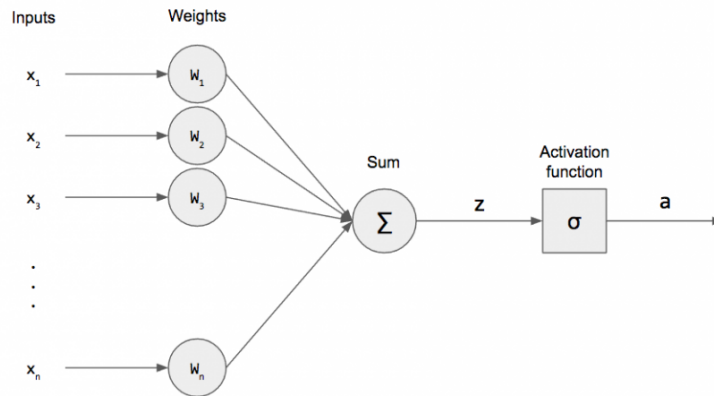
oppure ad una sigmoide [Nwa+18]

$$\sigma(x) = \frac{1}{1 + e^{-x}} \quad (2.7)$$

Nel layer finale questa funzione di attivazione varia a seconda della tipologia di problema: nel caso di regressione corrisponde all'identità, viceversa nella classificazione viene spesso usata una softmax [Kec14], che restituisce per l'elemento in posizione  $j$  nel layer di output

$$\sigma(\mathbf{z})_j = \frac{e^{z_j}}{\sum_{k=1}^K e^{z_k}} \quad (2.8)$$





**Figure 2.7.** Le operazioni algebriche per il calcolo dell'output di un singolo nodo

### Backpropagation

Fase fondamentale per una rete neurale è quella nella quale vengono analizzati i dati a disposizione (*training*): è questa la fase nella quale, attraverso la cosiddetta *backpropagation*, i pesi vengono adattati al problema in questione.

Questo corrisponde a cercare di minimizzare la seguente funzione di errore [Bis06]

$$E(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N \|\mathbf{y}(\mathbf{x}_n, \mathbf{w}) - \mathbf{t}_n\|^2 \quad (2.9)$$

con  $\mathbf{y}(\mathbf{x}_n, \mathbf{w})$  output della rete e  $\mathbf{t}_n$  target.

Questo miglioramento della rete viene effettuato modificando i pesi delle funzioni precedentemente definite, propagando all'indietro nella rete neurale il valore dell'errore: viene calcolata la dipendenza dell'errore da ciascuno dei pesi, i.e.

$$\frac{\partial E}{\partial w_{ij}} \quad (2.10)$$

Che viene quindi utilizzato per modificare i pesi nel seguente modo [Maz15]

$$w'_{ij} = w_{ij} - \eta \frac{\partial E}{\partial w_{ij}} \quad (2.11)$$

con  $\eta$  *learning step*, un parametro definito inizialmente.



# Bibliography

- [Bis06] Christopher M. Bishop. *Pattern recognition and machine learning*. springer, 2006.
- [CC08] Dan Campbell and Sherlock Campbell. “Introduction to regression and data analysis”. In: *StatLab Workshop Series*. 2008, pp. 1–15.
- [DDB15] Asit Kumar Datta, Madhura Datta, and Pradipta Kumar Banerjee. *Face Detection and Recognition*. Taylor & Francis, Oct. 28, 2015. 352 pp. URL: [https://www.ebook.de/de/product/25204083/asit\\_kumar\\_datta\\_madhura\\_datta\\_pradipta\\_kumar\\_banerjee\\_face\\_detection\\_and\\_recognition.html](https://www.ebook.de/de/product/25204083/asit_kumar_datta_madhura_datta_pradipta_kumar_banerjee_face_detection_and_recognition.html).
- [Kec14] Christian Keck. *Models for correspondence finding and probabilistic representative learning*. epubli GmbH, 2014. ISBN: 978-3-8442-9787-4. URL: <https://www.amazon.com/correspondence-finding-probabilistic-representative-learning/dp/3844297871?SubscriptionId=AKIAIOBINVZYXZQZ2U3A&tag=chimbiori05-20&linkCode=xm2&camp=2025&creative=165953&creativeASIN=3844297871>.
- [Maz15] Matt Mazur. *A Step by Step Backpropagation Example*. 2015. URL: <https://mattmazur.com/2015/03/17/a-step-by-step-backpropagation-example/>.
- [Nwa+18] Chigozie Nwankpa et al. “Activation Functions: Comparison of trends in Practice and Research for Deep Learning”. In: (Nov. 8, 2018). arXiv: <http://arxiv.org/abs/1811.03378v1> [cs.LG].
- [Sch13] Robert E. Schapire. “Explaining AdaBoost”. In: *Empirical Inference*. Springer Berlin Heidelberg, 2013, pp. 37–52. DOI: 10.1007/978-3-642-41136-6\_5.
- [SV08] Alex Smola and S. V. N. Vishwanathan. *Introduction to Machine Learning*. Ed. by Cambridge University Press. 2008. URL: <http://alex.smola.org/drafts/thebook.pdf>.
- [VJ04] Paul Viola and Michael J. Jones. “Robust Real-Time Face Detection”. In: *International Journal of Computer Vision* 57.2 (May 2004), pp. 137–154. DOI: 10.1023/b:visi.0000013087.49260.fb.
- [Wan14] Yi-Qing Wang. “An Analysis of the Viola-Jones Face Detection Algorithm”. In: *Image Processing On Line* 4 (June 2014), pp. 128–148. DOI: 10.5201/ipol.2014.104.